

基于Wolfe-Powell非精确一维搜索的拟牛顿算法

大数据学院 和泳毅 PB19010450

一维搜索过程是最优化方法的基本组成部分，精确一维搜索方法往往需要花费很大的工作量，特别是当迭代点远离问题的解时，精确地求解一个一维子问题通常不是十分有效的。实际上，很多最优化方法如牛顿法和拟牛顿法，其收敛速度并不依赖于精确一维搜索过程。因此，我们只需要保证目标函数 $f(\mathbf{x})$ 在每一步都有一定的下降量，同时保证步长不太小，这样就可以大大节省工作量。

在牛顿法中，面临的主要困难一是牛顿法是局部收敛的，当初始点选择不当时，往往导致不收敛；二是当Hesse矩阵 G_k 不正定时，不能保证产生的方向是下降方向。但是牛顿法二阶收敛是非常好的性质，为此人们在克服上述缺点方面做了很多工作，提出了许多拟牛顿法。比如用对称秩二校正公式推出的**DFP**法与**BFGS**法。

本文将使用基于**Wolfe-Powell**非精确一维搜索的拟牛顿法来解决无约束优化问题。

一、问题描述

给定目标函数 $f(\mathbf{x})$ ，求解以下无约束优化问题

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad (1)$$

并给出以下三个目标函数供测试：

Rosenbrock函数：

$$f(\mathbf{x}) = 100(x_1^2 - x_2)^2 + (x_1 - 1)^2$$

Beale函数：

$$f(\mathbf{x}) = (1.5 - x_1 + x_1 x_2)^2 + (2.25 - x_1 + x_1 x_2^2)^2 + (2.625 - x_1 + x_1 x_2^3)^2$$

McCormick函数：

$$f(\mathbf{x}) = \sin(x_1 + x_2) + (x_1 - x_2)^2 - 1.5x_1 + 2.5x_2 + 1$$

二、算法原理

(一) 最速下降法

定义1 (1) 设 $\bar{\mathbf{x}} \in S$, $\mathbf{d} \in \mathbb{R}^n$ 是非零向量。若存在 $\delta > 0$, 使得

$$\bar{\mathbf{x}} + \lambda \mathbf{d} \in S, \forall \lambda \in (0, \delta)$$

则称 \mathbf{d} 是 S 在 $\bar{\mathbf{x}}$ 处的可行方向。

(2) 设 $f(\mathbf{x})$ 是 \mathbb{R}^n 上的实函数, $\bar{\mathbf{x}} \in \mathbb{R}^n$, \mathbf{d} 是非零向量。若存在 $\delta > 0$, 使得

$$f(\bar{\mathbf{x}} + \lambda \mathbf{d}) < f(\bar{\mathbf{x}}), \forall \lambda \in (0, \delta)$$

则称 \mathbf{d} 为函数 $f(\mathbf{x})$ 在 $\bar{\mathbf{x}}$ 处的下降方向。

注意到, 满足 $f(\bar{\mathbf{x}})^T \mathbf{d} < 0$ 的 \mathbf{d} 为 $f(\mathbf{x})$ 在 $\bar{\mathbf{x}}$ 处的下降方向。

考虑问题(1), 一个自然的想法是产生点列 $\{\mathbf{x}^{(k)}\}$ 的函数列 $\{f(\mathbf{x}^{(k)})\}$ 为严格单调下降数列, 即对 $\forall k$, $f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$ 。

对 $f(\mathbf{x})$ 做 Taylor 展开

$$f(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + O(\|\mathbf{x} - \mathbf{x}^{(k)}\|^2).$$

取负梯度方向

$$\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)}),$$

则当 α_k 足够小时, 总有

$$f(\mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}) < f(\mathbf{x}^{(k)}).$$

于是有最速下降法:

Gradient

输入: 初始点 \mathbf{x}_0 , 终止误差 $\varepsilon > 0$ 。

(1) $k := 0$ 。

(2) 计算: $\mathbf{g}^{(k)} := \nabla f(\mathbf{x}^{(k)})$, 如果 $\|\mathbf{g}^{(k)}\| < \varepsilon$, 停止迭代。

(3) 令搜索方向 $\mathbf{d}^{(k)} = -\mathbf{g}^{(k)}$, 并由一维搜索确定步长 α_k 。

(4) 更新 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$, 置 $k := k + 1$, 返回步骤(2)。

输出: $\mathbf{x}^{(k)}$, $f(\mathbf{x}^{(k)})$ 。

定理1(最速下降法收敛定理) 设 $f \in C^1$, 最速下降法中的一维搜索采用(非)精确一维搜索过程, 则迭代点列 $\{\mathbf{x}^{(k)}\}$ 的每一个聚点是驻点。

总体全局性并未能保证最速下降法是一个有效的方法，因为最速下降方向仅是算法的局部性质，对于许多问题，最速下降法并非“最速下降”，而是下降非常缓慢。

(二) 牛顿法

牛顿法的基本思想是利用二次函数近似目标函数，把这个二次函数的极小点作为新的迭代点。

设 $f(\mathbf{x})$ 二次连续可微，求解问题(1)，在 $\mathbf{x}^{(k)}$ 处做Taylor展开取前三项，得到

$$q^{(k)}(\mathbf{s}) = f(\mathbf{x}^{(k)}) + \mathbf{g}^{(k)T} \mathbf{s} + \frac{1}{2} \mathbf{s}^T G_k \mathbf{s},$$

其中 $\mathbf{s} = \mathbf{x} - \mathbf{x}^{(k)}$ ， $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$ ， $G_k = \nabla^2 f(\mathbf{x}^{(k)})$ 。设 G_k 正定，那么上式有唯一极小点，是 $q^{(k)}(\mathbf{s})$ 的驻点，即使

$$\nabla q^{(k)}(\mathbf{s}) = \mathbf{g}^{(k)} + G_k \mathbf{s} = 0,$$

得到极小点

$$\mathbf{s}^{(k)} = -G_k^{-1} \mathbf{g}^{(k)}.$$

称搜索方向 $\mathbf{s}^{(k)}$ 为牛顿方向，在实际计算中， $\mathbf{s}^{(k)}$ 的计算常常通过解方程

$$G_k \mathbf{s} = -\mathbf{g}^{(k)},$$

得到。以下给出经典牛顿法迭代格式：

Newton

输入：初始点 \mathbf{x}_0 ，终止误差 $\varepsilon > 0$ 。

- (1) $k := 0$ 。
- (2) 计算： $\mathbf{g}^{(k)} := \nabla f(\mathbf{x}^{(k)})$ ，如果 $\|\mathbf{g}^{(k)}\| < \varepsilon$ ，停止迭代。
- (3) 解线性方程组 $G_k \mathbf{d} = -\mathbf{g}^{(k)}$ ，求出牛顿方向 $\mathbf{d}^{(k)}$ 。
- (4) 更新 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}$ ，置 $k := k + 1$ ，返回步骤(2)。

输出： $\mathbf{x}^{(k)}$ ， $f(\mathbf{x}^{(k)})$ 。

定理2(牛顿法收敛定理) 设 $f \in C^2$ ， \mathbf{x}^k 充分靠近 \mathbf{x}^* ，其中 $\nabla f(\mathbf{x}^*) = 0$ 。如果 $\nabla^2 f(\mathbf{x}^*)$ 正定，目标函数的Hesse矩阵 $G(\mathbf{x})$ 满足**Lipschitz**条件，则对一切的 k ，牛顿迭代有定义，所得序列 $\{\mathbf{x}^k\}$ 收敛到 \mathbf{x}^* ，且具有二阶收敛速率。

应该注意到，当初始点远离最优解时， G_k 不一定正定。牛顿方向不一定是下降方向，其收敛性不能保证。这说明恒取步长为1是不合适的，应该在牛顿法中采用一维搜索来确定步长。但是应该强调，仅当步长 $\{\alpha_k\}$ 收敛到1时，牛顿法才是二阶收敛的，于是产生了阻尼牛顿法。

(三) 拟牛顿法

牛顿法的突出优点是局部收敛很快，但运用牛顿法要计算二阶导，而且目标函数的Hesse阵可能非正定，甚至奇异。为了克服这些缺点，人们提出了拟牛顿法。其基本思想是：用不含二阶导数的矩阵 H_k 近似牛顿法中的Hesse矩阵的逆 $G(\mathbf{x}^{(k)})^{-1}$ 。

定义2 记 $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$, $\mathbf{y}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$ 则根据Taylor展开有

$$\nabla^2 f(\mathbf{x}^{(k+1)})\mathbf{s}^{(k)} \approx \mathbf{y}^{(k)} \quad \text{or} \quad \nabla^2 f(\mathbf{x}^{(k+1)})^{-1}\mathbf{y}^{(k)} \approx \mathbf{s}^{(k)}.$$

构造出Hesse矩阵的近似 B_{k+1} ，及其逆的近似 H_{k+1} 。使其满足

$$B_{k+1}\mathbf{s}^{(k)} = \mathbf{y}^{(k)}, \quad H_{k+1}\mathbf{y}^{(k)} = \mathbf{s}^{(k)}, \quad (2)$$

称为正割条件或拟牛顿条件。

定义3 (1) 对称秩一校正 (SR1)

$$H_{k+1} = H_k + a\mathbf{u}\mathbf{u}^T, (a \in \mathbb{R}, \mathbf{u} \in \mathbb{R}^n). \quad (3)$$

(2) 对称秩二校正 (SR2)

$$H_{k+1} = H_k + a\mathbf{u}\mathbf{u}^T + b\mathbf{v}\mathbf{v}^T, (a, b \in \mathbb{R}, \mathbf{u}, \mathbf{v} \in \mathbb{R}^n). \quad (4)$$

由SR1可以推导出对称秩一校正迭代格式：

$$H_{k+1} = H_k + \frac{(\mathbf{s}^{(k)} - H_k\mathbf{y}^{(k)}) (\mathbf{s}^{(k)} - H_k\mathbf{y}^{(k)})^T}{(\mathbf{s}^{(k)} - H_k\mathbf{y}^{(k)})^T \mathbf{y}^{(k)}}. \quad (5)$$

该迭代格式具有二次终止性，对二次函数有遗传性。但不能保证 H_{k+1} 的正定性，仅当 $(\mathbf{s}^{(k)} - H_k\mathbf{y}^{(k)})^T \mathbf{y}^{(k)} > 0$ 时，才能保证正定性。而这个条件往往很难保证。

引理 (Sherman-Morrison定理) 设 $A \in \mathbb{R}^{n \times n}$ 是非奇异矩阵， $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 是任意向量。若 $1 + \mathbf{v}^T A^{-1} \mathbf{u} \neq 0$ ，则 A 的秩一校正 $A + \mathbf{u}\mathbf{v}^T$ 非奇异，且其逆可以表示为

$$(A + \mathbf{u}\mathbf{v}^T)^{-1} = A^{-1} - \frac{A^{-1}\mathbf{u}\mathbf{v}^T A^{-1}}{1 + \mathbf{v}^T A^{-1} \mathbf{u}}.$$

1. DFP 法

由SR2以及拟牛顿条件(2)，有

$$H_{k+1}\mathbf{y}^{(k)} = H_k\mathbf{y}^{(k)} + \left(a\mathbf{u}^T\mathbf{y}^{(k)}\right)\mathbf{u} + \left(b\mathbf{v}^T\mathbf{y}^{(k)}\right)\mathbf{v} = \mathbf{s}^{(k)},$$

这里的 \mathbf{u} 和 \mathbf{v} 并不唯一确定，但有一种明确的选择是：

$$\begin{cases} \mathbf{u} = \mathbf{s}^{(k)}, & a\mathbf{u}^T\mathbf{y}^{(k)} = 1; \\ \mathbf{v} = H_k\mathbf{y}^{(k)}, & b\mathbf{v}^T\mathbf{y}^{(k)} = -1. \end{cases}$$

因此有

$$H_{k+1} = H_k + \frac{\mathbf{s}^{(k)}\mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T}\mathbf{y}^{(k)}} - \frac{H_k\mathbf{y}^{(k)}\mathbf{y}^{(k)T}H_k}{\mathbf{y}^{(k)T}H_k\mathbf{y}^{(k)}}. \quad (6)$$

上式被称DFP (Davidon-Fletcher-Powell) 校正公式。

定理3 (DFP公式的正定性) 当且仅当 $\mathbf{s}^{(k)T}\mathbf{y}^{(k)} > 0$ 时，DFP校正公式(6)保持正定性。

证： 式(6)满足拟牛顿条件(2)。当且仅当对某个非奇异矩阵 J_{k+1} ，有

$$H_{k+1} = J_{k+1}J_{k+1}^T$$

时， H_{k+1} 正定。

定理的必然性显然，事实上，若 H_{k+1} 正定，则存在非奇异矩阵 J_{k+1} 使得 $J_{k+1}J_{k+1}^T\mathbf{y}^{(k)} = \mathbf{s}^{(k)}$ 。定义 $\mathbf{w}^{(k)} = J_{k+1}^T\mathbf{y}^{(k)}$ ， 则

$$\mathbf{s}^{(k)T}\mathbf{y}^{(k)} = \mathbf{y}^{(k)T}J_{k+1}J_{k+1}^T\mathbf{y}^{(k)} = \mathbf{w}^{(k)T}\mathbf{w}^{(k)} > 0$$

必要性得证。下面证明充分性。设 $H_k = L_kL_k^T$ 是正定矩阵 H_k 的Cholesky分解，式(6)可以写成

$$\begin{aligned} H_{k+1} &= H_k + \left(\frac{1}{\beta}\right)^{1/2} H_k\mathbf{y}^{(k)}\mathbf{s}^{(k)T} - \frac{1}{\mathbf{y}^{(k)T}H_k\mathbf{y}^{(k)}} H_k\mathbf{y}^{(k)}\mathbf{y}^{(k)T}H_k \\ &\quad + \left(\frac{1}{\beta}\right)^{1/2} \mathbf{s}^{(k)}\mathbf{y}^{(k)T}H_k - \frac{H_k\mathbf{y}^{(k)}\mathbf{y}^{(k)T}H_k}{\mathbf{y}^{(k)T}H_k\mathbf{y}^{(k)}} + \frac{1}{\mathbf{s}^{(k)T}\mathbf{y}^{(k)}} \mathbf{s}^{(k)}\mathbf{s}^{(k)T} \\ &\quad - \left(\frac{1}{\beta}\right)^{1/2} \mathbf{s}^{(k)}\mathbf{y}^{(k)T}H_k - \left(\frac{1}{\beta}\right)^{1/2} H_k\mathbf{y}^{(k)}\mathbf{s}^{(k)T} + \frac{H_k\mathbf{y}^{(k)}\mathbf{y}^{(k)T}H_k}{\mathbf{y}^{(k)T}H_k\mathbf{y}^{(k)}} \\ &= J_{k+1}J_{k+1}^T, \end{aligned}$$

其中

$$J_{k+1} = L_k + \frac{(\mathbf{s}^{(k)} - L_k \mathbf{w}^{(k)}) \mathbf{w}^{(k)T}}{\mathbf{w}^{(k)T} \mathbf{w}^{(k)}},$$

$$w_k = \left(\frac{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}} \right)^{1/2} L_k^T \mathbf{y}^{(k)},$$

$$\beta = \left(\mathbf{s}^{(k)T} \mathbf{y}^{(k)} \right) \left(\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)} \right).$$

注意到

$$\begin{aligned} & 1 + \frac{1}{\mathbf{w}^{(k)T} \mathbf{w}^{(k)}} \mathbf{w}^{(k)T} L_k^{-1} \cdot (\mathbf{s}^{(k)} - L_k \mathbf{w}^{(k)}) \\ &= 1 + \frac{1}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} \left(\frac{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}} \right)^{1/2} \mathbf{y}^{(k)T} L_k \cdot L_k^{-1} \cdot \left[\mathbf{s}^{(k)} - \left(\frac{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}} \right)^{\frac{1}{2}} H_k \mathbf{y}^{(k)} \right] \\ &= \left(\frac{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}} \right)^{1/2} \end{aligned}$$

以及 $\mathbf{s}^{(k)T} \mathbf{y}^{(k)} > 0$, H_k 正定, 故上式大于零。从而再由引理可知秩一校正的矩阵 J_{k+1} 可逆, 从而DFP公式产生的 H_{k+1} 正定。

以下给出**DFP**法迭代格式:

DFP

输入: 初始点 \mathbf{x}_0 , 终止误差 $\varepsilon > 0$ 。

- (1) 初始化 $H_0 = I$, $k := 0$ 。
- (2) 计算搜索方向: $\mathbf{d}^{(k)} := -H_k \nabla f(\mathbf{x}^{(k)})$, 如果 $\|\mathbf{g}^{(k)}\| < \varepsilon$, 停止迭代。
- (3) 一维搜索确定步长 α_k , 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ 。
- (4) 令 $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$, $\mathbf{y}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$, 当 $\mathbf{s}^{(k)T} \mathbf{y}^{(k)} > 0$ 作更新:

$$H_{k+1} = H_k + \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}. \text{ 置 } k := k + 1, \text{ 返回步骤 (2).}$$

输出: $\mathbf{x}^{(k)}$, $f(\mathbf{x}^{(k)})$ 。

对于一般线性函数, 校正保持正定性, 因而 $\mathbf{d}^{(k)}$ 总是下降方向, 且具有超线性的收敛速度。但进一步研究发现, DFP方法具有数值不稳定性, 以下给出的BFGS校正克服了这个缺点。

2. BFGS法

类似地, 可以从拟牛顿条件 (2) 得到关于 B_k 的对称秩二校正公式

$$B_{k+1}^{(BFGS)} = B_k + \frac{\mathbf{y}^{(k)} \mathbf{y}^{(k)T}}{\mathbf{y}^{(k)T} \mathbf{s}^{(k)}} - \frac{B_k \mathbf{s}^{(k)} \mathbf{s}^{(k)T} B_k}{\mathbf{s}^{(k)T} B_k \mathbf{s}^{(k)}},$$

在对上式两次应用引理的求逆公式就得到了 H_K 的BFGS校正公式

$$H_{k+1}^{(BFGS)} = H_k + \left(1 + \frac{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{s}^{(k)T} + \mathbf{s}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}}. \quad (7)$$

以下给出**BFGS**法迭代格式：

BFGS

输入：初始点 \mathbf{x}_0 ，终止误差 $\varepsilon > 0$ 。

- (1) 初始化 $H_0 = I$ ， $k := 0$ 。
- (2) 计算搜索方向： $\mathbf{d}^{(k)} := -H_k \nabla f(\mathbf{x}^{(k)})$ ，如果 $\|\mathbf{g}^{(k)}\| < \varepsilon$ ，停止迭代。
- (3) 一维搜索确定步长 α_k ，令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$ 。
- (4) 令 $\mathbf{s}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ ， $\mathbf{y}^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$ ，作更新：

$$H_{k+1}^{(BFGS)} = H_k + \left(1 + \frac{\mathbf{y}^{(k)T} H_k \mathbf{y}^{(k)}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} \mathbf{s}^{(k)T}}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}} - \frac{H_k \mathbf{y}^{(k)} \mathbf{s}^{(k)T} + \mathbf{s}^{(k)} \mathbf{y}^{(k)T} H_k}{\mathbf{s}^{(k)T} \mathbf{y}^{(k)}},$$
置 $k := k + 1$ ，返回步骤(2)。

输出： $\mathbf{x}^{(k)}$ ， $f(\mathbf{x}^{(k)})$ 。

(四) 基于黄金分割准则的精确一维步长搜索

在迭代格式中，通过求解一维最优化问题

$$\min_{\alpha \geq 0} \varphi(\alpha) = f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}), \quad (8)$$

来确定步长。此时称为精确一维搜索。

黄金分割法是一种分割方法，基本思想是通过取试探点和进行函数值的比较，使包含极小点的搜索区间不断缩小，当区间缩短到一定程度时，区间上的各点均接近极小值，可以看作是极小值的近似。

详细迭代过程如下：

Gold_div_search

输入：迭代点 $\mathbf{x}^{(k)}$ ，搜索区间 $[a, b]$ ，精度要求 $\varepsilon > 0$ 。

- (1) 初始化试探点， $\alpha_1 = a + 0.382(b - a)$ ， $\alpha_2 = a + 0.618(b - a)$ 。计算 $\varphi_1 = \varphi(\alpha_1)$ ， $\varphi_2 = \varphi(\alpha_2)$ 。
- (2) 如果 $b - a \leq \varepsilon$ ，算法结束。否则如果 $\varphi_1 > \varphi_2$ ，进入步骤(3)；如果 $\varphi_1 < \varphi_2$ ，进入步骤(4)；如果 $\varphi_1 = \varphi_2$ ，进入步骤(5)。
- (3) 令 $a = \alpha_1$ ， $\alpha_1 = \alpha_2$ ， $\alpha_2 = a + 0.618(b - a)$ ，返回步骤(2)。
- (4) 令 $b = \alpha_2$ ， $\alpha_2 = \alpha_1$ ， $\alpha_1 = a + 0.382(b - a)$ ，返回步骤(2)。
- (5) 令 $a = \alpha_1$ ， $b = \alpha_2$ ， $\alpha_1 = a + 0.382(b - a)$ ， $\alpha_2 = a + 0.618(b - a)$ ，返回步骤(2)。

输出： α_1 。

（五）基于Wolfe-Powell准则的非精确一维步长搜索

在实际计算中，往往不是求解一维最优化问题(8)，而是找出满足某些适当条件的粗略近似解作为步长，此时称为非精确一维搜索。

Wolfe-Powell准则给出条件

$$\varphi(\alpha) \leq \varphi(0) + \rho\alpha\varphi'(0) \quad (9)$$

$$\varphi'(x) \geq \sigma\varphi'(0) \quad (10)$$

其中式(10)是精确线性搜索满足的正交条件 $\mathbf{g}^{(k+1)T}\mathbf{d}^{(k)} = 0$ 的近似。以下给出迭代格式：

Wolfe_Powell

输入：迭代点 $\mathbf{x}^{(k)}$ ，搜索区间 $[0, \bar{\alpha}]$ ， $\rho \in (0, \frac{1}{2})$ ， $\sigma \in (\rho, 1)$ 。

(1) 计算 $\varphi_0 = \varphi(0)$ ， $\varphi'_0 = \varphi'(0)$ ，令 $a_1 = 0$ ， $a_2 = \bar{\alpha}$ ， $\varphi_1 = \varphi_0$ ， $\varphi'_1 = \varphi'_0$ 。选取 $\alpha \in (a_1, a_2)$ 。

(2) 计算 $\varphi = \varphi(\alpha)$ ，若 $\varphi(\alpha) \leq \varphi(0) + \rho\alpha\varphi'(0)$ ，进入步骤(3)；否则，由 $\varphi_1, \varphi'_1, \varphi$ 构造多项式 $P^{(1)}$ 并得到极小点 $\hat{\alpha} = a_1 + \frac{1}{2} \frac{(a_1 - \alpha)^2 \varphi'_1}{(\varphi_1 - \varphi) - (a_1 - \alpha)\varphi'_1}$ ，令 $a_2 = \alpha$ ， $\alpha = \hat{\alpha}$ ，重复步骤(2)。


(3) 计算 $\varphi' = \varphi'(\alpha)$ ，若 $\varphi'(x) \geq \sigma\varphi'(0)$ ，则输出 $\alpha_k = \alpha$ ，算法停止；否则，由 $\varphi, \varphi', \varphi'_1$ 构造多项式 $P^{(2)}$ 并得到极小点 $\hat{\alpha} = \alpha - \frac{(a_1 - \alpha)\varphi'}{\varphi'_1 - \varphi'}$ ，令 $a_1 = \alpha$ ， $\alpha = \hat{\alpha}$ ， $\varphi_1 = \varphi$ ， $\varphi'_1 = \varphi'$ ，返回步骤(2)。

输出： α 。

三、测试函数说明

Rosenbrock函数：


$$f(\mathbf{x}) = 100(x_1^2 - x_2)^2 + (x_1 - 1)^2$$



最优解为 $f(1, 1) = 0$ 。

Beale函数：


$$f(\mathbf{x}) = (1.5 - x_1 + x_1 x_2)^2 + (2.25 - x_1 + x_1 x_2^2)^2 + (2.625 - x_1 + x_1 x_2^3)^2$$



当搜索区间为 $-4.5 \leq x, y \leq 4.5$ 时最优解为 $f(3, 0.5) = 0$ 。

McCormick函数：

$$f(\mathbf{x}) = \sin(x_1 + x_2) + (x_1 - x_2)^2 - 1.5x_1 + 2.5x_2 + 1$$



当搜索区间为 $-1.5 \leq x \leq 4$ ， $-3 \leq y \leq 4$ 时最优解为 $f(-0.54719, -1.54719) = -1.9133$ 。

四、程序输入输出说明

1.

请输入需要测试的函数：

【1】 *Rosenbrock*

【2】 *Beale*

【3】 *McCormick*

首先选择需要测试的函数，输入1\2\3以回车结束。

2.

请输入需要使用的方法：

【1】采用精确一维搜索的最速下降法

【2】经典牛顿法

【3】采用基于 $Wolfe - Powell$ 非精确一维搜索的 DFP 法

【4】采用基于 $Wolfe - Powell$ 非精确一维搜索的 $BFGS$ 法

其次选择需要测试的方法，输入1\2\3\4以回车结束。

3.

请输入初始点：

最后输入初始点，两个坐标值以空格隔开，回车结束。

4.

迭代11次

最优解: $x_1 = 2.9995974679750543, x_2 = 0.49988731493905675$

最优值: $f = 2.9754691805977275e - 08$


程序输出迭代次数，最优解，最优值。

五、程序测试结果

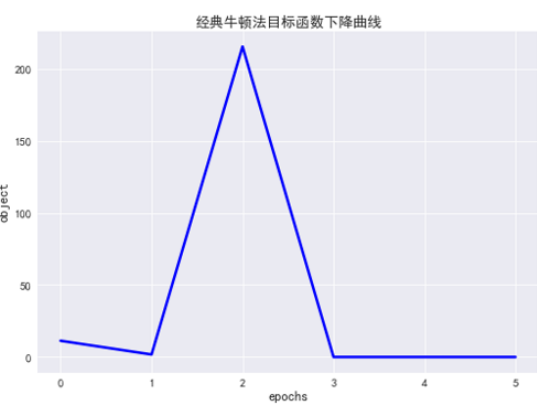

1. Rosenbrock函数

考察在同一初始点 $(-0.3, 0.4)$ 下不同算法的效果

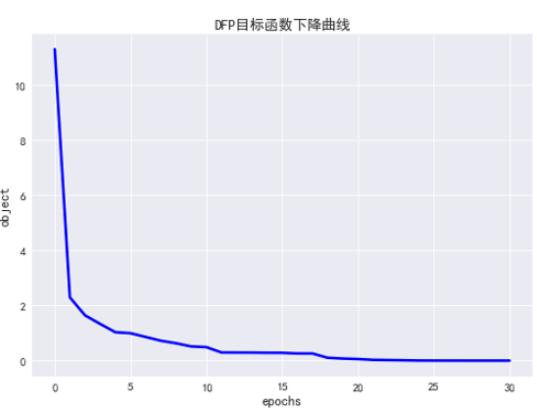

采用精确一维搜索的最速下降法：





采用经典牛顿法：



采用基于**Wolfe-Powell**非精确一维搜索的**DFP**法:



采用基于**Wolfe-Powell**非精确一维搜索的**BFGS**法:



算法	最优解	最优值	次数
最速下降法	(0.9999999368454756, 0.9999999368454756)	4.754338744371732e-15	203
经典牛顿法	(0.999999999999997, 0.999999999953213)	2.1884018353647033e-21	6
DFP	(0.999999999999961, 0.99999999999775)	2.1818475153974118e-26	31
BFGS	(1.0000000003482363, 1.0000000007088101)	1.364898433414235e-19	25


考察基于**Wolfe-Powell**非精确一维搜索的**BFGS**法在不同初始点下的效果:

初始点	最优解	最优值	次数
(0.5, 0.5)	(0.9999999999645257, 0.9999999999304009)	1.4405338339947363e-21	15
(-0.5, -0.5)	(1.0000000001169451, 1.0000000002594174)	7.88396281863918e-20	25
(-2, -5)	(1.0000000023260547, 1.0000000048258566)	8.429340684293242e-18	38
(10, -5)	(1.0000000000009632, 1.0000000000026739)	5.678880697649583e-23	65
(10, -50)	(0.999999997694025, 0.999999995469737)	5.984815360609098e-20	66
(100, -50)	(1.0000000007796892, 1.0000000013279087)	5.965738947584368e-18	288
(100, -500)	(1.0000000000001712, 1.000000000000408)	4.583745808153962e-25	287


2. Beale函数

考察在同一初始点(0.5, 0.5)下不同算法的效果


采用精确一维搜索的最速下降法：



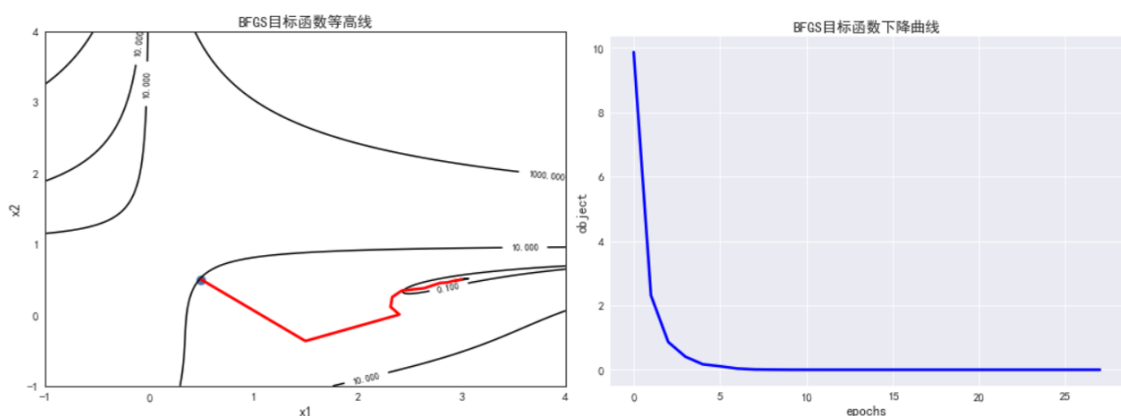
采用经典牛顿法：



采用基于Wolfe-Powell非精确一维搜索的DFP法：



采用基于**Wolfe-Powell**非精确一维搜索的**BFGS**法：



算法	最优解	最优值	次数
最速下降法	(2. 8755968600817567, 0. 46705811823227883)	0. 002857305563428932	6
经典牛顿法	(2. 9995974679750543, 0. 49988731493905675)	2. 9754691805977275e-08	11
DFP	(3. 000000006963388, 0. 5000000049195799)	2. 428723111796065e-16	31
BFGS	(3. 000000043525999, 0. 5000000149328366)	6. 984822518127638e-16	28

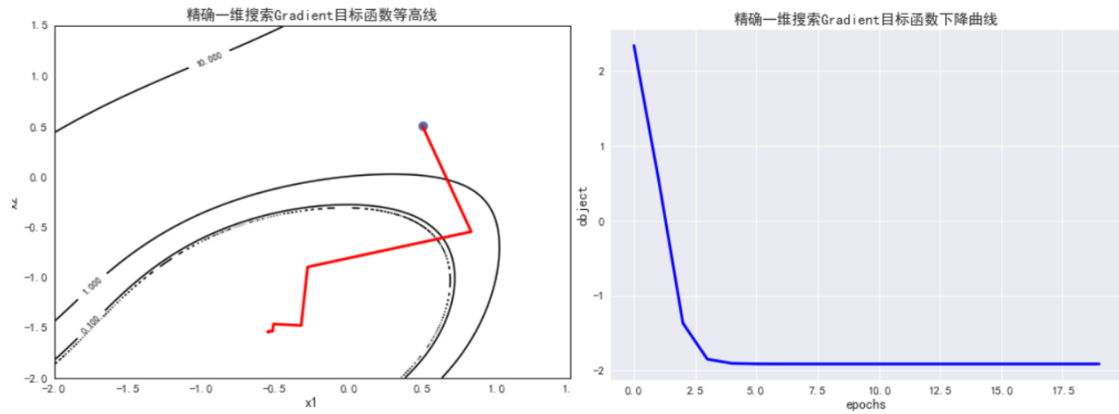
考察基于**Wolfe-Powell**非精确一维搜索的**BFGS**法在不同初始点下的效果：

初始点	最优解	最优值	次数
(0.5, 0.5)	(3. 0000000673826563, 0. 5000000185873378)	8. 081377965410317e-16	19
(-0.5, -0.5)	(2. 99999997187749, 0. 4999999934602392)	1. 3092642229480963e-16	29
(2, 0)	(3. 0000000686409236, 0. 5000000185604835)	8. 08817943744345e-16	21
(0, 0)	(3. 000000058152033, 0. 5000000189682727)	1. 0183999029410446e-15	20
(2, 2)	无法收敛	\	\
(-2, 2)	解非最优	\	\
(-2, -2)	解非最优	\	\

3. McCormick函数

考察在同一初始点(0.5, 0.5)下不同算法的效果

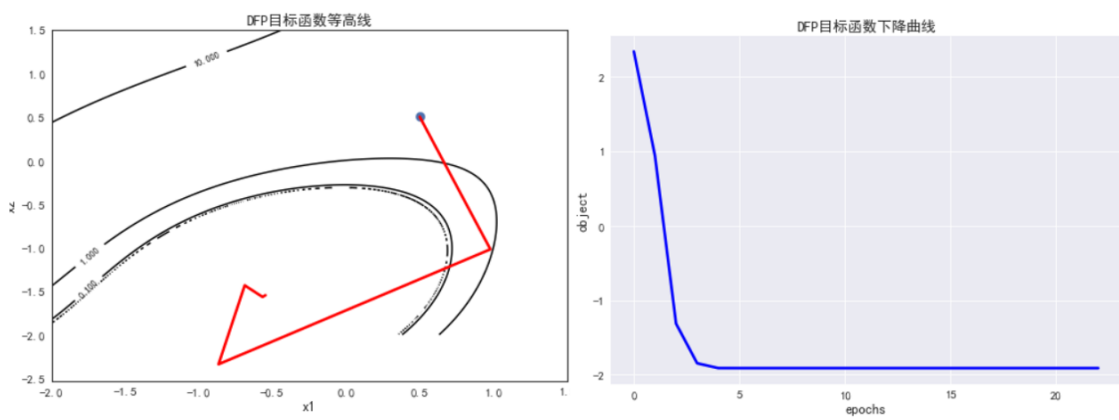
采用精确一维搜索的最速下降法：



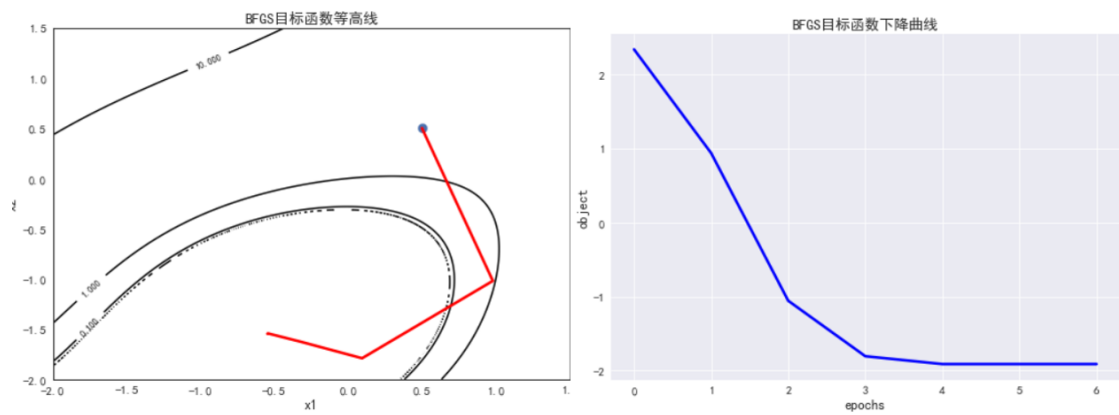
采用经典牛顿法：

Hesse矩阵奇异，无法求解

采用基于Wolfe-Powell非精确一维搜索的DFP法：



采用基于Wolfe-Powell非精确一维搜索的BFGS法：



算法	最优解	最优值	次数
最速下降法	$(-0.547197539167360, -1.547197532106908)$	-1.9132229549810358	20
经典牛顿法	无法求解	\	\
DFP	$(-0.547197565531484, -1.547197564933061)$	-1.9132229549810362	23
BFGS	$(-0.547197551201126, -1.547197551033523)$	-1.9132229549810362	7

考察基于**Wolfe-Powell**非精确一维搜索的**BFGS**法在不同初始点下的效果：

初始点	最优解	最优值	次数
$(0.5, 0.5)$	$(-0.547197551201126, -1.547197551033523)$	-1.9132229549810362	7
$(-0.5, -0.5)$	$(-0.547197527042834, -1.547197531988847)$	-1.9132229549810353	5
$(-2, 0)$	$(-0.547197550723614, -1.547197551524310)$	-1.9132229549810367	4
$(0, 0)$	$(-0.547197544313902, -1.547197577894429)$	-1.9132229549810353	25
$(2, 2)$	解非最优	\	\
$(-2, 2)$	$(-0.547197551227754, -1.547197551268341)$	-1.9132229549810362	5
$(-4, 4)$	$(-0.547197551164487, -1.547197551138525)$	-1.9132229549810367	5

六、分析总结

在目标函数足够“好”的情况下，牛顿法以及拟牛顿法的收敛速度都要比最速下降法快很多。并且牛顿法也比拟牛顿法收敛得更快，但可能存在一定的震荡现象。而实际情况中，目标函数往往不具有很好的性质，这时候牛顿法可能不再适用，需要使用拟牛顿法来完成求解。

同时，不同的初始点也可能产生截然不同的结果，甚至无法收敛。这与目标函数的性质有关系。例如，如果目标函数存在局部梯度很小或很大的情况，将对该区域的初始点造成很大的影响，所以选择一个恰当的初始点也是一个需要认真对待的工作。所以建议求解问题之前，可以观察目标函数的图像等方式来推测其性质，从而选择合适的算法，并在可能的最优解附近选取合适的初始点开始迭代。

最后，经过三个测试函数发现，**BFGS**法往往具有比最速下降法更快的收敛速度，比经典牛顿法跟广泛的适用对象，比**DFP**法更稳定的数值，是一个很好的迭代算法，如果配合合适的初始点，往往产生很好的效果。

七、参考文献

[1] 吴祈宗, 侯福均. 运筹学与最优化方法(第2版)[M]. 机械工业出版社, 2013:105-108, 112-117, 122-125.

[2] 袁亚湘, 孙文瑜. 最优化理论与方法[M]. 科学出版社, 1991:96-100, 108-110, 121-124, 224-233.